



Apunte de cátedra: Azúcar sintáctico

El *azúcar sintáctico* es un término acuñado por Peter J. Landin [2] para designar a la *sintaxis redundante* que se le agrega a un lenguaje de programación para que sea más fácil la escritura y la lectura de los programas.

Se establece entonces una distinción entre construcciones esenciales del lenguaje, y aquellas que pueden ser explicadas mediante una traducción a las construcciones esenciales, sin agregar expresividad. Pero, ¿a qué nos referimos con expresividad? ¿Son todos los lenguajes Turing-completos igual de expresivos? Felleisen introduce una noción formal más útil de expresividad [1]: informalmente, un lenguaje es más expresivo que otro si nos permite observar más distinciones desde dentro del lenguaje. Una consecuencia de esta idea es que dos lenguajes son igual de expresivos si se puede traducir de uno a otro mediante cambios *locales*. Por lo tanto llamamos azúcar sintáctico a la sintaxis que se puede eliminar mediante cambios locales.

1. Azucarando PCF

Para hacer más agradable la programación extendemos PCF_0 con azúcar sintáctico.

1.1. Términos

Vamos a permitir hacer definiciones locales usando `let`. Para ellos definimos

$$\text{let } x : \tau = t \text{ in } t' \stackrel{\text{def}}{=} (\text{fun } (x : \tau) \rightarrow t') t$$

Para escribir las funciones en una forma más familiar definimos:

$$\text{let } f (x : \tau) : \tau' = t \text{ in } t' \stackrel{\text{def}}{=} \text{let } f : \tau \rightarrow \tau' = \text{fun } (x : \tau) \rightarrow t \text{ in } t'$$

Además permitimos definir funciones de varios argumentos:

$$\text{fun } (x_1 : \tau_1) \dots (x_n : \tau_n) \rightarrow t \stackrel{\text{def}}{=} \text{fun } (x_1 : \tau_1) \rightarrow \dots \rightarrow \text{fun } (x_n : \tau_n) \rightarrow t$$

$$\text{let } f (x_1 : \tau_1) \dots (x_n : \tau_n) : \tau = t \text{ in } t' \stackrel{\text{def}}{=} \text{let } f : \tau_1 \rightarrow \dots \rightarrow \tau_n \rightarrow \tau = \text{fun } (x_1 : \tau_1) \dots (x_n : \tau_n) \rightarrow t \text{ in } t'$$

Para facilitar la definición de funciones recursivas definimos:

$$\text{let rec } f (x : \tau) : \tau' = t \text{ in } t' \stackrel{\text{def}}{=} \text{let } f : \tau \rightarrow \tau' = (\text{fix } (f : \tau \rightarrow \tau') (x : \tau) \rightarrow t) \text{ in } t'$$

Usamos `let rec` para definir funciones, así que también lo extendemos a varios argumentos.

$$\begin{aligned} \text{let rec } f (x_1 : \tau_1) \dots (x_n : \tau_n) : \tau = t \text{ in } t' \\ \stackrel{\text{def}}{=} \text{let rec } f (x_1 : \tau_1) : \tau_2 \rightarrow \dots \rightarrow \tau_n \rightarrow \tau = \text{fun } (x_2 : \tau_2) \dots (x_n : \tau_n) \rightarrow t \text{ in } t' \end{aligned}$$

1.2. Declaraciones

Introducimos azúcar sintáctico para declaraciones en forma análoga a los casos de términos `let` y `let rec`.

$$\text{let } f (x : \tau) : \tau' = t \stackrel{\text{def}}{=} \text{let } f : \tau \rightarrow \tau' = \text{fun } (x : \tau) \rightarrow t$$

$$\text{let } f (x_1 : \tau_1) \dots (x_n : \tau_n) : \tau = t \stackrel{\text{def}}{=} \text{let } f : \tau_1 \rightarrow \dots \rightarrow \tau_n \rightarrow \tau = \text{fun } (x_1 : \tau_1) \dots (x_n : \tau_n) \rightarrow t$$

$$\text{let rec } f (x : \tau) : \tau' = t \stackrel{\text{def}}{=} \text{let } f : \tau \rightarrow \tau' = \text{fix } (f : \tau \rightarrow \tau') (x : \tau) \rightarrow t$$

$$\text{let rec } f (x_1 : \tau_1) \dots (x_n : \tau_n) : \tau = t \stackrel{\text{def}}{=} \text{let rec } f (x_1 : \tau_1) : \tau_2 \rightarrow \dots \rightarrow \tau_n \rightarrow \tau = \text{fun } (x_2 : \tau_2) \dots (x_n : \tau_n) \rightarrow t$$

Por otro lado, por uniformidad y para soporte de futuros cambios, no permitiremos las declaraciones sin tipo (al estilo de `let x = t`), requiriendo declaraciones:

$$\text{let } x : \tau = t$$

1.3. Operadores

El programa `let f (g : Nat -> Nat) : Nat = t in f succ` no es un término de PCF_0 , ya que en PCF_0 el operador unario `succ` debe estar aplicado a un término. La solución es η -expandir el término de la siguiente manera:

$$\text{let } f \text{ (g : Nat } \rightarrow \text{ Nat) : Nat = t in } f \text{ (fun (x : Nat) } \rightarrow \text{ succ x)}$$

Para permitir los operadores unarios sin aplicar, realizaremos la η -expansión en las ocurrencias no aplicadas de los operadores `succ` y `pred`. Notar que sólo queremos hacer la η -expansión en las ocurrencias no aplicadas para no introducir una aplicación innecesaria.

1.4. Sinónimos de Tipos

El azúcar sintáctico también se puede aplicar a los tipos. Introducimos en nuestro lenguaje la posibilidad de declarar sinónimos de tipos

$$\text{type } n = \tau$$

El significado de esta declaración es que, de aquí en adelante, n debe interpretarse como τ . La declaración en sí no se convierte en una declaración de PCF_0 .

Al lenguaje azucarado lo llamamos PCF_1 .

1.5. Opcional: multibinders

En cada construcción del lenguaje que puede tener varios binders (`fun`, `let` y `let rec`, tanto en términos como declaraciones), podemos abreviar el caso cuando muchos binders consecutivos comparten un tipo de la siguiente forma:

$$\stackrel{\text{def}}{=} \begin{array}{ll} \text{let } f \vec{b}_0 (x_0 \ x_1 \cdots x_n : \tau) & \vec{b}_1 : \tau' = t \\ \text{let } f \vec{b}_0 (x_0 : \tau) (x_1 : \tau) \cdots (x_n : \tau) & \vec{b}_1 : \tau' = t \end{array}$$

Donde \vec{b}_0 y \vec{b}_1 representan otros binders. Así, podemos escribir una declaración para la función *suma* vista anteriormente como:

```
let rec suma (m n : Nat) : Nat =
  ifz n then m else succ (suma m (pred n))
```

Ejercicios

1. Traduzca los siguientes términos de PCF_1 a PCF_0 según las reglas de arriba:

- a) `let x : Nat = 2 in succ x`
- b) `fun (x:Nat) -> x`
- c) `let id (x:Nat) : Nat = x in id 10`
- d) `let app5 (f : Nat -> Nat) : Nat = f 5 in app5 succ`
- e) `fun (x:Nat) (y:Nat) -> ifz x then y else 1`

2. Traduzca las siguientes declaraciones de PCF_1 a PCF_0 según las reglas de arriba:

- a) `let rec doble (x:Nat) : Nat = ifz x then 0 else succ (succ (doble (pred x)))`
- b) `let rec ack (m:Nat) (n:Nat) : Nat =`

```
  ifz m
  then succ n
  else (ifz n
        then ack (pred m) 1
        else ack (pred m) (ack m (pred n)))
```

2. Implementación

Como vimos antes, el azúcar sintáctico hace más agradable a PCF_0 al permitirnos escribir funciones con muchos argumentos, `let rec` en vez de un `fix` explícito, etc. Otra forma de lograr esto es agregar estas nuevas funcionalidades al lenguaje, directamente al AST interno (**Term**), por ejemplo con nodos **Let** y **LetRec**, y cambiando **Fun** para tomar una lista de binders. Pero esto implicaría cambiar *todas* las fases posteriores para trabajar con estos nuevos constructores (typechecking, pretty-printing, compilación, etc). Al implementar estas funcionalidades con azúcar sintáctico, estos cambios solamente deben ser espolvoreados en las primeras capas del compilador.

Hay dos maneras distintas de implementar el azúcar sintáctico, aunque en ambas (claramente) debe modificarse el parser para reconocer las nuevas construcciones. Como primer alternativa se puede implementar directamente en el parser, agregando una regla para parsear, por ejemplo, `let x : τ = t in t'` que genere el mismo término que `(fun (x: τ) -> t') t`. La segunda opción, es definir un tipo de AST “superficial” que contiene nodos que representan el azúcar sintáctico (p. ej. **Let**), y que el parser usa directamente. Luego, hay una etapa de *desugaring* que convierte el AST superficial al AST interno, que no tiene azúcar. Este desacoplamiento puede ser conveniente: al dividir lo que es el parsing del azúcar, las transformaciones quedan más explícitas y el código se torna más mantenible. Por otro lado, tener un AST superficial permite usar el pretty-printer para *formatear* archivos fuente. Podemos tomar un archivo, parsearlo hasta el AST superficial (sin elaborarlo), y pretty-printearlo nuevamente con indentación adecuada. Si usamos la opción anterior, el parser cambiaría la sintaxis del archivo al remover el azúcar (los **Let** desaparecerían), algo que no es deseable para un formateador. A veces, el AST superficial incluye hasta un nodo de paréntesis, para poder conservar `(f g) h`, y otros, como tal. Otras ventajas incluyen que depurar el parser se hace más fácil, y a medida que las transformaciones aumentan es más fácil implementarlas.

En ambos casos, la impresión de términos (ya elaborados) se ve afectada al perder el azúcar. Algunos compiladores intentan imprimir estos términos de mejor manera, por ejemplo manteniendo información sobre como se desugareó un término o intentando reconstruir la forma azucarada a partir de la interna. Si se guardan anotaciones en el AST interno para reconstruir la versión azucarada, es importante que solamente sean usadas para imprimir, y de esta manera estar seguros de que el significado del azúcar sólo es dado por el desugaring.

2.1. Azúcar en PCF_1

Implementar el azúcar directamente en el parser es posible, aunque con las desventajas que listamos más arriba. La segunda opción requiere crear un nuevo tipo de datos para el AST superficial e implementar las traducciones. Si bien ambos enfoques son aceptables para la materia, recomendamos la segunda opción.

Concretamente, recomendamos definir un tipo **STm** que contenga nuevos nodos para el azúcar (p. ej. **SLet**), y cuyos nodos para funciones (**SLam** y **SFix**) tengan una lista de binders (`[(Name, Ty)]`) en vez de uno o dos respectivamente. La etapa de desugaring convertirá un **SLam** con muchas variables a una aplicación sucesiva de nodos **Lam** internos. En el parser, conviene escribir una regla que parsee una lista de binders (`binders :: P [(Name, Ty)]`), que puede reusarse muchas veces. La etapa de elaboración puede ser recursiva, por ejemplo (como en las reglas dadas arriba) al encontrar un `let rec`, podemos transformarlo en un término (superficial) que contiene un **SLam** con muchas variables, y luego elaborarlo recursivamente a funciones anidadas. Luego definir en el módulo **Elab** una función **desugar** que transforme términos **STm** en términos internos con nombre **NTerm**. Luego una elaboración completa se obtiene combinando **desugar** (que remueve el azúcar sintáctico) con la función **elab** (que transforma de una representación con nombres a una representación locally nameless).

En la sintaxis dada, se requiere que un `let rec` tenga al menos un argumento para poder elaborarlo a un `fix`, entre otros requerimientos similares. Hay dos opciones aquí: el parser puede fallar si no hay un argumento, dando un error de sintaxis, o podemos parsear una lista de binders vacía y hacer que la elaboración falle (con gracia, via **failPosPCF**). La segunda opción tiene la ventaja que permite errores mas descriptivos, pero tiene la desventaja que requiere agregar la posibilidad de que la elaboración fracase.

Referencias

- [1] Matthias Felleisen. On the expressive power of programming languages. *Science of Computer Programming*, 17(1):35 – 75, 1991.
- [2] Peter J. Landin. The Mechanical Evaluation of Expressions. *The Computer Journal*, 6(4):308–320, 01 1964.